[Project Summary] 위성 영상을 활용한 북극 해빙 예측 AI

[배경] 지구 온난화 진행으로 지구 표면 온도 상승, 이상 기온, 해수면 상승 등 다양한 기후 변화가 관측 되고 있으며, 북극 해빙 또한 지구 온난화의 영향으로 매년 면적이 줄어들고 있는 중임

[목표] 과거 관측된 해빙 데이터를 통해 앞으로의 변화할 해빙 예측

[데이터 EDA]

제공 데이터 셋 (이미지 데이터 (448 x 304))

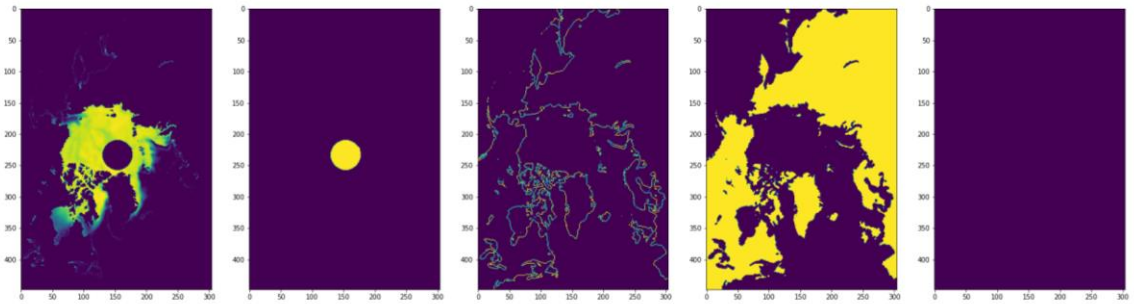

- 1978년 11월부터 2018년 12월까지 448 x 304 크기의 5개 월별 데이터를 제공
- 각 파일은 해빙 농도(0~250), 북극점(관측 불가 영역), 해안선, 육지선, 결측값을 제공
- 해안선,육지선, 결측값은 모든 데이터에서 동일하여 제외하고 사용

관측 불가 영역 추이

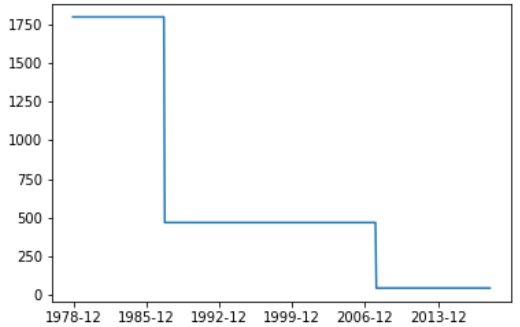

평균 해빙농도 추이(월별 vs 5년 이동평균)

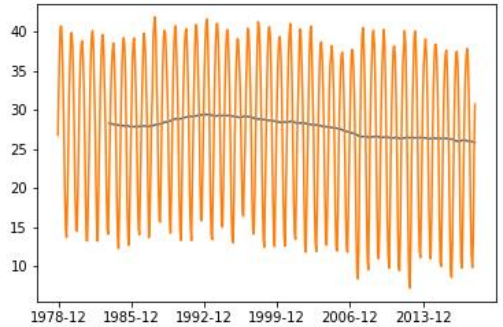

- 관측 불가 영역이 기술 발전에 따라 줄어드는 것을 볼 수 있음
- 해빙농도의 월별 추이는 cyclical 하나 5년 이동평균으로는 조금씩 감소하는 것을 포착
- 감소 추이를 모델이 잘 잡을 수 있도록 최근 15년 데이터만을 사용

[Approach]

이미지의 dim이 448 x 304로 크기 때문에 computing burden을 줄이면서 학습/예측 할 수 있는 모델이 필요

1. Autoencoder의 encoder 를 통한 차원 축소 후, encoded 데이터를 이용하여 sequential 모델을 학습/예측
2. 원래 이미지를 여러 개의 작은 이미지로 cropping 하여 모델을 학습/예측 후 원래 이미지 크기로 재 가공

[Approach 1-1] AutoEncoder의 Encoder을 사용한 Dimension Reduction을 위해 AutoEncoder Model 탐색

- 예측이 불가했던 공간을 해당 이미지 해빙 농도의 Median 값으로 채운 후 448 x 304 크기의 이미지를 256 길이의 vector로 추출
- Conv2D를 사용한 여러 모델 중 Filters 16개와 32개의 Conv2D + MaxPool을 사용한 모델이 가장 좋은 결과를 보임
- SGD optimizer의 learning rate=0.1, momentum=0.9를 사용하여 700 epochs train 후 Val loss=0.0541 달성

[Best Model Architecture]

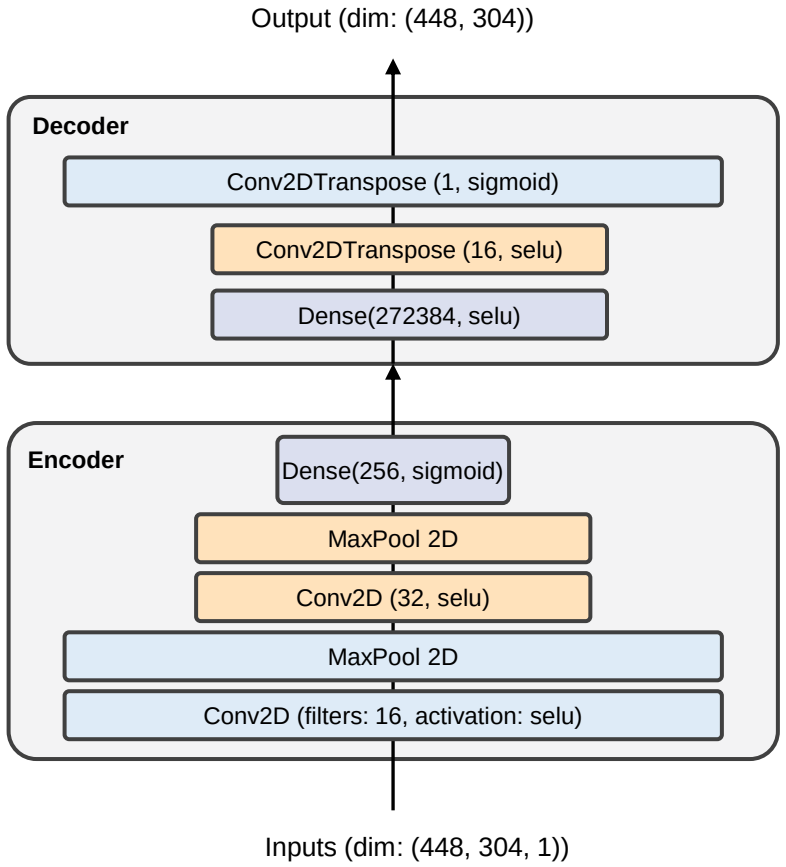

[Summary of Models]

Model (All Ran for 100 epochs)	Validation Loss
One Conv2D(filters: 16)+Maxpool layer	**0.0860**
Two Conv2D(filters: 16 & 32)+Maxpool layers	**0.0569**
Two Conv2D(filters: 16 & 32)+Maxpool layers with Dense layer weights synced in Encoder and Decoder	**0.0606**
Two Conv2D layers with smaller filters (filters: 8 & 16)	**0.0577**
Three Conv2D layers (filters: 16 & 32 & 64)	**0.0581**

[Final AutoEncoder images(top), Inputted Raw Images(Bottom)]

Output Image

Input Image

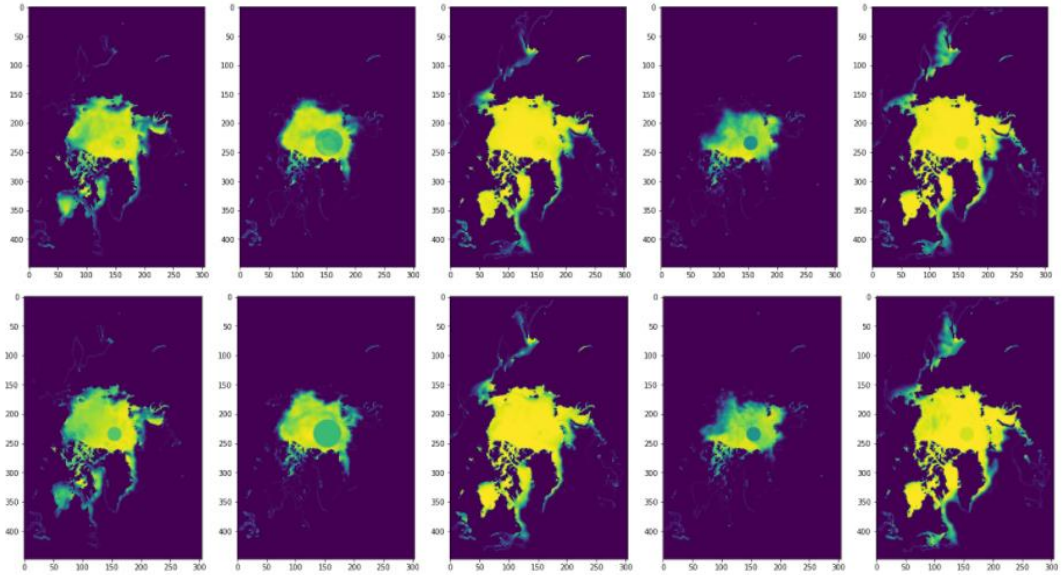

[Approach 1-2] LSTM을 이용한 encoded sequential data 예측 모델 발굴

- **Input data** : predict year의 전 5년간의 Encoded된 데이터; **Ouput Data** : predict year의 encoded data 예측 후 Decoder를 통한 image 생성
- Target image에 대한 loss를 정확히 파악할 수 있도록 Decoder 모델을 prediction 모델 후에 추가하여 이미지를 출력
- 2 개의 LSTM Layer과 Batch Norm을 더한 모델이 가장 좋은 결과를 보임. SGD(learning rate=0.001, momentum=0.999)와 400 epochs 훈련 후 Val Loss 0.0600 달성

[Best Model Architecture]

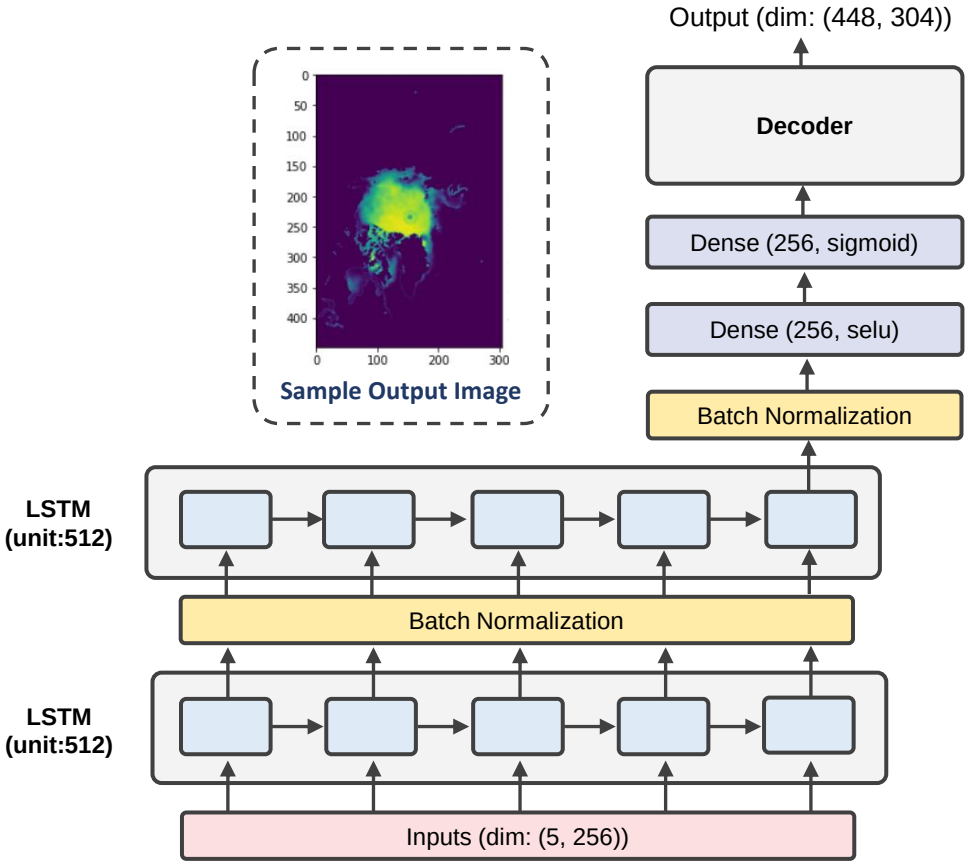

[Summary of Models]

Model (All ran for 100 epochs)	Validation Loss
One LSTM layer (512 units)	**0.0611**
Two LSTM layers (512 units)	**0.0614**
Three LSTM layers (512 units)	**0.0626**
One LSTM layer with Batch Normalization (512 units)	**0.0620**
Two LSTM layer with Batch Normalization (512 units)	**0.0605**
Bigger LSTM unit with 1 layer (1024 units)	**0.0611**
Bigger LSTM unit with 2 layers (1024 units)	**0.0615**
Smaller LSTM unit with 1 layer (128 units)	**0.0616**
Conv2D before LSTM (2 filters, kernel size: 3, LSTM 512 units)	**0.0609**
Conv2D before 2 LSTM layers(2 filters, kernel size: 3, LSTM 512 units)	**0.0622**

Loss: Binary Crossentropy; optimizer : SGD

[Approach 1-2] Multi-Head Self Attention을 이용한 encoded sequential data 예측

- **Input data** : predict year의 전 5년간의 Encoded된 데이터; **Ouput Data** : predict year의 encoded data 예측 후 Decoder를 통한 image 생성; **Decoder 추가**
- **Idea**: Sequential Data의 상호 유사도와 중요도를 파악하는 Self-Attention 모델을 사용해서 이미지 데이터 또한 학습
- Google Research Team이 고안한 Transformer의 Encoder 모델과 Vision Transformer Model의 Encoder 모델을 인용
- 단순 BatchNorm, MultiHead, Dense를 이용한 모델에 Skip layer를 추가한 모델이 더 좋은 성능을 보임

[Best Model Architecture]

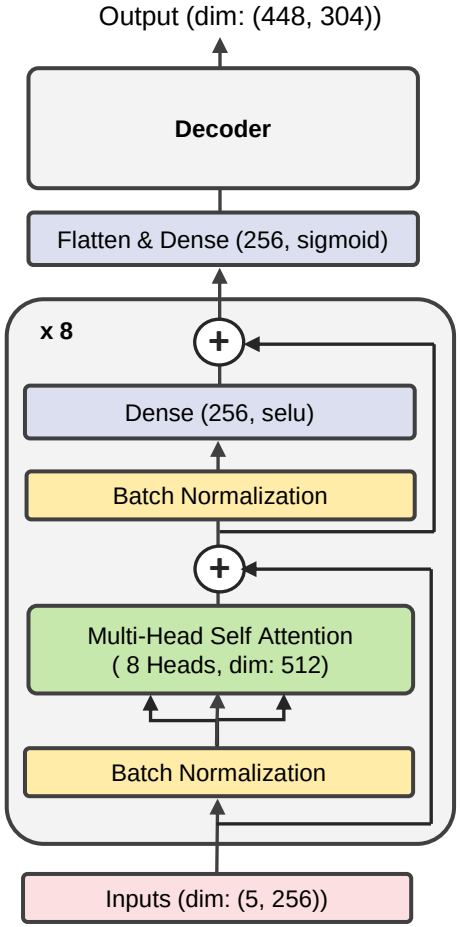

[Summary of Models]

Model(Ran for 100 epochs)	Validation Loss
(BatchNorm + MultiHead + BatchNorm + Dense) x 4	**0.0635**
((BatchNorm + MultiHead + BatchNorm + Dense) + Skip Layer) x 8	**0.0611**

Loss: Binary Crossentropy; optimizer : Adam

[참고 논문]

- An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale, 2020, Google Research Team; arXiv:2010.11929
- Attention Is All You Need, 2017, Google Research Team; arXiv:1706.03762

[Approach 2-1] 분할 예측을 위해 이미지를 Crop 및 예측 후 결합을 위한 Image pad 생성

- 예측 모델의 전산 처리가 가능하도록 전체 이미지를 24 pixels 씩 아래옆으로 움직이면서 64 x 64 사이즈 이미지로 cropping
- 예측을 위해 Cropping 된 이미지를 5년간 데이터 셋으로 re-grouping 한 후 input 데이터로 이용
- 예측된 이미지의 pixel 값을 본래 이미지에 더하면 중첩 값들이 생김으로, 중첩 값들을 평균 내주기 위한 image pad을 생성
- Image pad는 24 pixel 씩 움직이면서 64 x 64 이미지 위치에 pixel 값을 1 씩 더해줌, 추후에 이를 element-wise division으로 이용

[Image Cropping 방식]

Window size = 64, strides = 24

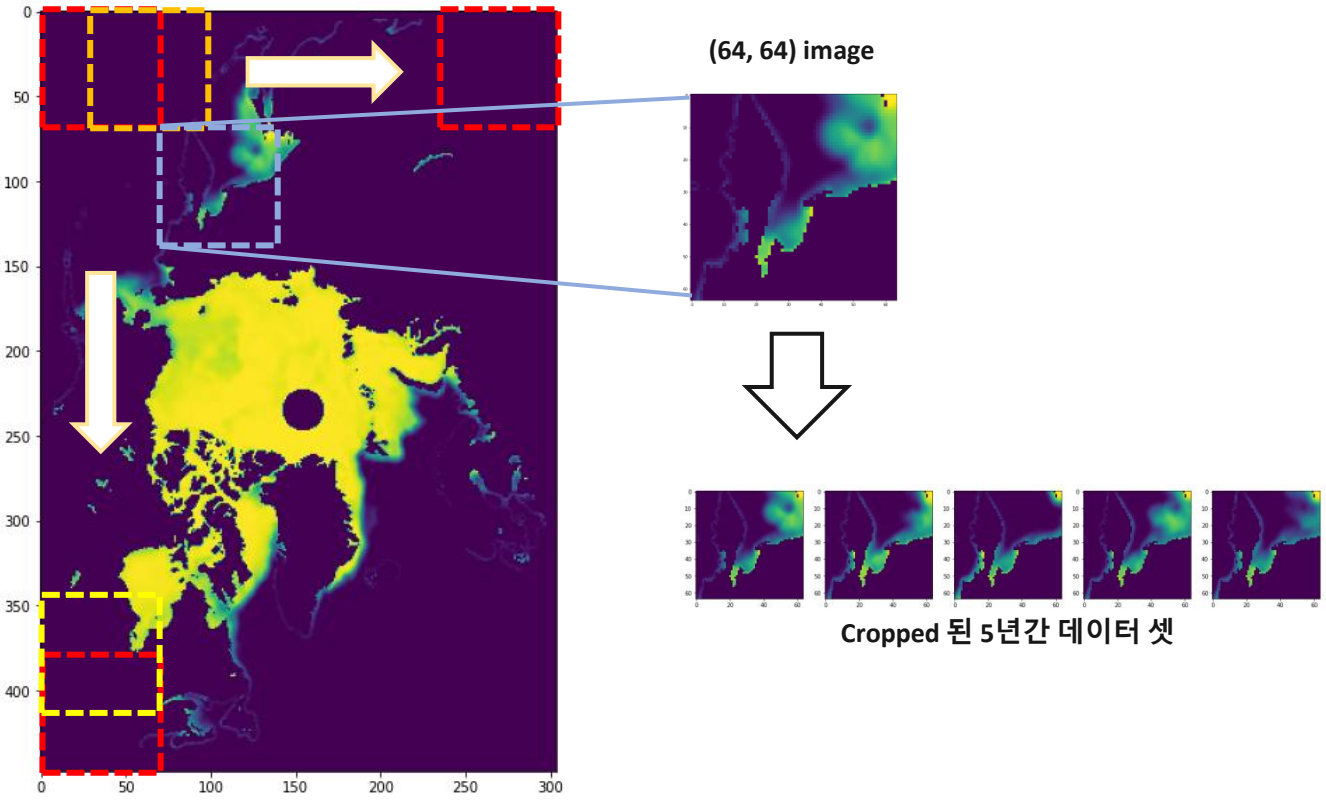

[전체 Image 예측시 Division에 사용되는 Image Pad]

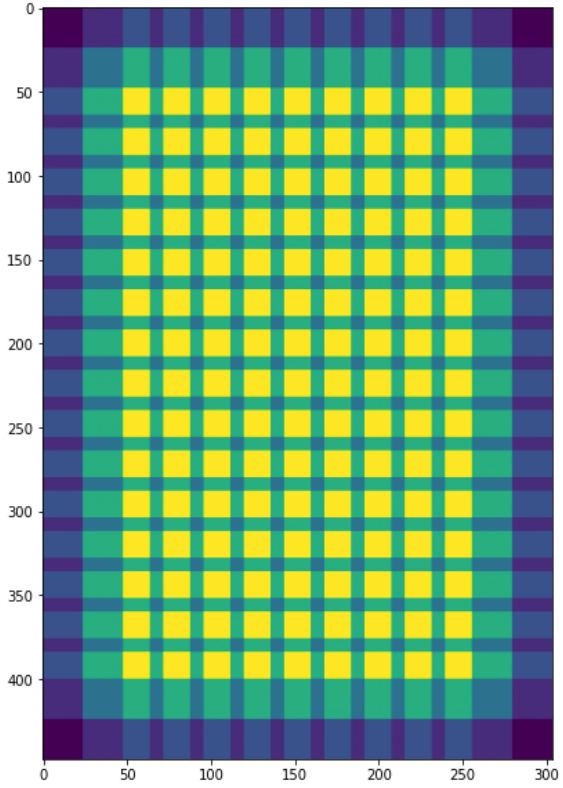

[Approach 2-2] Cropped Image를 이용하여 큰 이미지를 분할하여 예측

- **Input data** : predict year의 전 5년간의 cropped image; **Ouput Data** : predict year의 이미지의 cropped된 한 부분
- 앞에서 보았던 모델들 중 좋은 결과를 보인 Two Layers LSTM+BatchNorm, Multi-Head Attention 모델과 시계열 이미지 처리가 가능한 ConvLSTM 이용
- ConvLSTM과 BatchNorm layer 3개와 sigmoid 함수를 last layer에 사용한 모델이 MAE 2.95를 보여주며 가장 좋은 성과를 보임
- 이미지가 Cropped 후에도 메모리가 크고 epoch train 시간이 오래걸려(1시간 이상) loss가 더이상 줄어들지 않는 모델들은 중간에 training을 멈추었음

[Best Model Architecture]

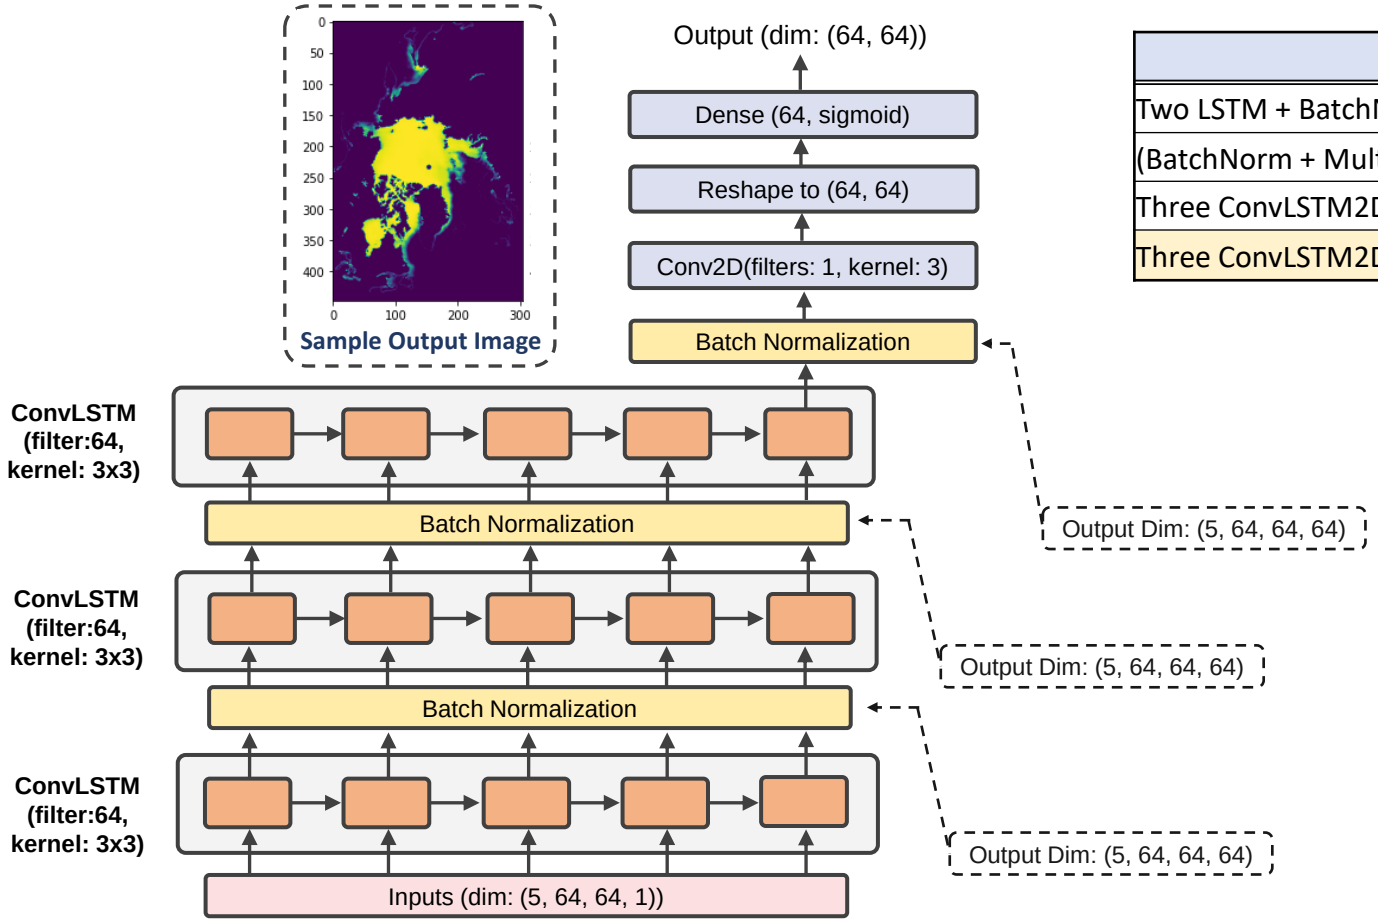

[Summary of Models]

Model	Validation Loss
Two LSTM + BatchNorm Layers	**18.3465 (6 epochs)**
(BatchNorm + MultiHead + BatchNorm + Dense) x 2 + Dense	**19.5847 (11 epochs)**
Three ConvLSTM2D + BatchNorm layers and Dense(64, relu)	**5.1563 (20 epochs)**
Three ConvLSTM2D + BatchNorm layers and Dense(64, sigmoid)	**≈2.9500 (20 epochs)***

Loss: Mean Absolute Error; optimizer : Adam
* Model input and output scaled to values between 0 and 1.
So, MAE * 250 is used to approximate. (original mae:0.0118)

[Final Evaluation] Train한 모델들을 이용하여 Test Data를 예측

- 앞서 보았던 모델들을 이용하여 Test Data를 예측하고 pixel 값이 5~50인 pixel 값에 집중하여 Final Score 를 계산
- 세 모델의 Final Score은 0.1~0.2 정도 아주 큰 차이를 보이지는 않으나, Multi-Head Attention을 사용한 모델이 가장 좋은 결과 값을 보임
- 각 모델을 epochs 중 Val Loss 가 가장 작은 값이 나오는 모델들로 저장하여 predict 하였음

[Final Evaluation Metric]

```python
import numpy as np

def mae_score(true, pred):
    # Regular MAE 계산
    score = np.mean(np.abs(true-pred))

    return score

def f1_score(true, pred):
    # target 이미지의 픽셀 값이 5~50 사이인 값만을 계산
    target = np.where((true>250*0.05)&(true<250*0.5))

    # 픽셀값 15를 threshold로 나눔
    true = true[target]
    pred = pred[target]
    true = np.where(true < 250*0.15, 0, 1)
    pred = np.where(pred < 250*0.15, 0, 1)

    # precision 과 recall 계산
    right = np.sum(true * pred == 1)
    precision = right / np.sum(true+1e-8)
    recall = right / np.sum(pred+1e-8)
    score = 2 * precision*recall/(precision+recall+1e-8)

    return score

def mae_over_f1(true, pred):
    # mae 를 f1 으로 나눔
    mae = mae_score(true, pred)
    f1 = f1_score(true, pred)
    score = mae/(f1+1e-8)

    return score
```

[Summary of Models]

Model		Final Score
With Autoencoder	Two Conv2D(filters: 16)+Maxpool layers	**4.6961 (700 epochs)**
With Autoencoder	((BatchNorm + MultiHead + BatchNorm + Dense) + Skip Layer) x 8	**4.4870 (200 epochs)**
With Cropped images	Three ConvLSTM2D + BatchNorm layers and Dense(64, sigmoid)	**4.5689 (40 epochs)**